

Plan de Développement : Chatbot d'Investigation Anti-Fraude

Étudiant : Ambdulghaffar Ahamadi

Projet choisi : **Projet 4 - Chatbot d'Investigation : Dialogue LLM**

19 avril 2026

Introduction

Ce document retrace la chronologie de développement du projet de Chatbot d'Investigation CCFD (Credit Card Fraud Detection). Le projet a suivi une approche agile sur 4 semaines, alternant entre l'ingénierie des données sur Kaggle et le déploiement applicatif via Streamlit. L'objectif principal était de coupler un socle statistique robuste (Machine Learning) à une intelligence cognitive (LLM Llama-3) pour transformer la détection de fraude en investigation interactive.

1 Semaine 1 : Pipeline de Données Hybride & Context Engineering

Objectif : Unifier les sources de données et établir un ancrage probabiliste objectif.

1.1 Tâche 1 : Ingestion et Qualité (Kaggle)

- Extraction et fusion des datasets *PaySim* (transactions mobiles) et *ULB* (carte bancaire).
- Vérifications de qualité : suppression des doublons (1081 détectés), vérification des valeurs nulles et des montants négatifs.
- Division Train/Test (80-20) stratifiée avec verrouillage du *Test Set* pour l'évaluation finale.

1.2 Tâche 2 : Scoring Baseline & Calibration

- Implémentation du calcul de **Score de Risque Baseline** (0 à 1) calculé AVANT l'appel au LLM.
- Calibration qualitative des seuils : **LOW** (< 0.4), **MEDIUM** ($0.4-0.7$), et **HIGH** (≥ 0.7).
- Validation de la cohérence : les fraudes réelles affichent un score moyen de 0.76 contre 0.31 pour les transactions légitimes.

1.3 Tâche 3 : Moteur de Traduction "Context Translator"

- Développement du *Context Translator* universel transformant les données brutes (V1-V28 pour ULB, balances pour PaySim) en récits narratifs structurés.
- Injection automatique du score de risque dans le prompt pour guider le raisonnement du modèle.

2 Semaine 2 : Architecture Cognitive & Classes d'Objets

Objectif : Définir les briques logicielles et l'intelligence de l'agent.

2.1 Tâche 1 : Modélisation Orientée Objet (src/)

- Classe `ChatHistory` : Gestion de la mémoire de travail et cycle de vie des questions.
- Classe `ContextManager` : Maintien de l'état global et des métadonnées de l'enquête.
- Intégration de la librairie JSON pour forcer le LLM à produire des réponses structurées (Status, Confiance, Justification).

2.2 Tâche 2 : Intégration API LLM (Groq)

- Connexion au client *Groq Cloud* pour exploiter le modèle **Llama-3-70B**.
- Optimisation de la latence via l'infrastructure LPU pour garantir une interactivité fluide.

2.3 Tâche 3 : Développement des "Tools" d'Investigation

- Simulation d'outils externes (Géolocalisation, Historique, Analyse Marchand).
- Mécanisme de *Tool Calling* simplifié permettant au bot de "penser" avant de poser une question au client.

3 Semaine 3 : Moteur "Self-Play", Production Métriques ML

Objectif : Mise à l'épreuve du système et évaluation scientifique massive.

3.1 Tâche 1 : Simulateur de Client Robuste

- Création d'un simulateur *Rule-Based* répondant aux questions du bot selon la "Vérité Terrain" (`is_fraud`) pour éviter les hallucinations circulaires.
- Configuration des profils : Fraudeur agressif/pressé vs Client légitime précis/calme.

3.2 Tâche 2 : Production Massive (30 Investigations)

- Exécution automatisée de 30 enquêtes complètes (15 fraudes / 15 légitimes) couvrant tous les niveaux de risque.
- Sauvegarde des transcriptions au format JSON pour analyse approfondie.

3.3 Tâche 3 : Analyse Statistique & Visualisation (Graphviz)

- Calcul des performances : Rappel exceptionnel de **93%** (détection quasi-totale des fraudes).
- Génération automatique de la matrice de confusion et des courbes ROC/PR via *Matplotlib/Seaborn*.
- Modélisation du workflow global via *Graphviz* pour documentation technique.

4 Semaine 4 : Déploiement Streamlit Sécurisation Finale

Objectif : Transformation du prototype en application Web utilisable par des agents de sécurité.

4.1 Tâche 1 : Développement de l'Interface Web

- Création de l'application `app.py` avec le framework *Streamlit*.
- **Mode Live Investigation** : Chatbot interactif avec jauges de risque dynamiques et visualisation des outils utilisés.
- **Dashboard Analytique** : Vue d'ensemble des 30 investigations passées pour supervision humaine.

4.2 Tâche 2 : Sécurité et "Red Teaming"

- Durcissement du *System Prompt* pour bloquer les tentatives de *Jailbreak*.
- Protection contre les injections de prompt : le chatbot refuse de "sortir de son rôle" ou de donner des recettes de cuisine.

4.3 Tâche 3 : Finalisation et Optimisation

- Correction des bugs de boucle infinie (Perrot Bug).
- Optimisation du design (Glassmorphism) et rédaction du rapport technique final de 46 pages.