

Plan de Développement : Mini-Projets CCFD

Étudiant : Ambdulghaffar Ahamadi

Projet choisi : **Projet 4 - Chatbot d'Investigation : Dialogue LLM**

Introduction

Dans le cadre du module de Détection de Fraude Cartes Bancaires (CCFD), j'ai choisi de réaliser le **Projet 4**. Ce projet vise à concevoir un agent conversationnel (LLM) capable de mener une enquête interactive pour valider ou bloquer une transaction suspecte.

Voici le plan d'action détaillé sur 4 semaines, structuré pour garantir une approche hybride (Machine Learning classique + IA Générative) et éviter le sur-apprentissage.

1 Semaine 1 : Pipeline de Données Hybride & "Context Translator"

Environnement : Kaggle

Objectif : Unifier deux sources de données hétérogènes et établir un ancrage probabiliste robuste avant l'intervention de l'IA.

1.1 Tâche 1 : Ingestion et Qualité des Données

- **Ingestion Hybride** : Chargement conjoint du dataset *PaySim* (données explicites) et du dataset *ULB* (données anonymisées V1-V28).
- **Data Quality Check** : Implémentation de verrous de vérification (valeurs nulles, montants négatifs, doublons) avant traitement.
- **Stratégie Anti-Surapprentissage** : Division stricte des données (Train/Test 80-20) avec stratification pour préserver la distribution des fraudes. Le *Test Set* est verrouillé jusqu'à la semaine 4.

1.2 Tâche 2 : Scoring Baseline et Calibration (Le Cerveau Logique)

- **Modélisation Baseline** : Entraînement d'un modèle léger (RandomForest ou Logistic Regression) pour obtenir un score de risque initial.
- **Calibration** : Conversion du score probabiliste (0-1) en niveaux qualitatifs (**LOW**, **MEDIUM**, **HIGH**) pour guider le LLM.
- **Validation** : Vérification de la cohérence des moyennes de scores (Fraude vs Légitime) pour valider le signal.

1.3 Tâche 3 : Context Engineering (Le Traducteur)

- **Traducteurs Spécifiques** :
 - *PaySim* : Transformation narrative des flux (ex : "Virement de type TRANSFER...").
 - *ULB* : Mapping narratif des variables techniques (V1-V28) pour les rendre intelligibles.

- **Injection de Garde-fous** : Intégration du niveau de risque et du score baseline dans le prompt système pour empêcher le LLM de classer "Légitime" une transaction à risque critique sans preuve.

2 Semaine 2 : Architecture Cognitive (Mémoire vs Contexte)

Environnement : Kaggle

Objectif : Coder l'intelligence conversationnelle en séparant la mémoire court-terme des outils d'investigation.

2.1 Tâche 1 : Gestion de la Mémoire (State Management)

- Implémentation d'une structure de données (`chat_history`) persistante pour conserver le fil de la conversation (rôles User/Assistant) et éviter les répétitions.

2.2 Tâche 2 : Contexte Dynamique (External Tools)

- **Simulation d'Outils** : Développement de fonctions Python simulant l'accès aux bases de données bancaires (ex : `get_geo_location`, `get_client_history`).
- **Mécanisme de RAG simplifié** : Le LLM utilise des balises spécifiques (ex : `<TOOL:GEO>`) pour requêter une information manquante. Le système intercepte la demande et injecte la donnée.

2.3 Tâche 3 : Confiance et Décision

- Configuration de la sortie du LLM pour inclure un objet JSON invisible contenant un score de confiance et le statut de l'enquête (ex : `{"confidence": 85, "status": "INVESTIGATING"}`).

3 Semaine 3 : Production de Données & "Self-Play"

Environnement : VS Code ou Antigravity (Migration locale)

Objectif : Générer un corpus de dialogues pour l'évaluation statistique.

3.1 Tâche 1 : Configuration "Self-Play" (Bot vs Bot)

- Mise en place d'une simulation automatisée :
 - **Agent 1 (Enquêteur)** : Le chatbot développé en Semaine 2.
 - **Agent 2 (Simulateur Client)** : Un LLM configuré pour jouer le rôle du titulaire de la carte, utilisant les données réelles du dataset pour répondre.

3.2 Tâche 2 : Boucle de Génération de Logs

- Exécution automatique sur 30 transactions du *Test Set* (15 Fraudes / 15 Légitimes).
- Enregistrement structuré (JSON) incluant : Vérité terrain, Prédiction du bot, Score de confiance, Durée et Transcription complète.

4 Semaine 4 : Interface & Métriques Data Science

Environnement : VS Code + Streamlit

Objectif : Validation scientifique des performances et interface utilisateur.

4.1 Tâche 1 : Calcul des Métriques (Scientificité)

- Analyse des logs générés en Semaine 3 via `sklearn.metrics` :
 - **Matrice de Confusion** : Visualisation des Faux Positifs/Négatifs.
 - **Scores de Performance** : Calcul de la Précision, du Rappel (Recall) et du F1-Score.
 - **Métriques Opérationnelles** : Temps moyen de résolution et corrélation entre la confiance du bot et la réalité.

4.2 Tâche 2 : Interface Graphique (GUI)

- Développement d'une application web **Streamlit** comprenant :
 - **Page Chatbot** : Interface de dialogue temps réel pour démonstration.
 - **Page Dashboard** : Visualisation des métriques de performance et graphiques d'analyse.